接真实模型 · 操作指南

> 目标：把 MOCK 模型换成真实线上模型，验证**语义层**（参谋拟的方案到底能不能看）。 全程约 15 分钟，其中 10 分钟在等平台注册/充值审核。 代码一行都不用改——只填一个配置文件。

零、如果你不熟悉命令行：双击就行

项目里已经放好三个批处理文件，**双击即可运行**，不用学终端命令：

文件	作用	什么时候用
`1_自检模型.bat`	检查配置、连通性、JSON 输出	拿到 key 后**先跑这个**
`2_跑验收测试.bat`	跑 6 条验收用例	自检通过后
`3_单条提问.bat`	自己输入一个问题试试	想单独问一句时

双击后会弹出黑窗口，跑完显示"按任意键关闭窗口"，看完再关。

> 若想用命令行，在项目文件夹**顶部地址栏**里直接输入 `powershell` 并回车， 会弹出一个已经定位到当前目录的窗口，再粘贴命令即可。

一、拿 API Key（约 10 分钟）

推荐：DeepSeek 开放平台（便宜、OpenAI 兼容、注册即用）

步骤	做什么	地址
1	注册/登录（手机号即可）	https://platform.deepseek.com
2	进入 **API Keys** 菜单 → **创建 API Key**	https://platform.deepseek.com/api_keys
3	**立刻复制保存**——密钥只显示这一次，关掉就没了	—
4	充值（新用户通常有赠送额度，够跑很多轮测试）	平台内「充值」

备选平台（都是 OpenAI 兼容，换 `base_url` + 模型名即可）

平台	控制台	适用
智谱 GLM	https://bigmodel.cn	中文强，有免费额度模型
阿里云百炼	https://bailian.console.aliyun.com	企业常用，模型全
Moonshot Kimi	https://platform.moonshot.cn	长文本
硅基流动	https://cloud.siliconflow.cn	一个 key 调多家模型

> **模型名一律以平台实际返回为准**：填完 key 后跑 `python check_llm.py --models`，它会把你账号能用的模型全列出来，从里面挑。 别照抄网上的模型名——`deepseek-chat` 已在 2026-07-24 退役，本项目 `.env.example` 早期就写的这个名字，现已修正。

二、填配置文件（约 1 分钟）

在项目根目录执行（**Git Bash**）：

```
cp config/.env.example config/.env
```

或 **PowerShell**：

```
Copy-Item config\.env.example config\.env
```

然后用记事本/VSCode 打开 `config/.env`，改这三行：

```
LLM_BASE_URL=https://api.deepseek.com
LLM_API_KEY=sk-xxxxxxxxxxxxxxx          ← 粘贴你刚复制的 key
LLM_MODEL_MAIN=deepseek-flash           ← 先用便宜的，够用就不加钱
LLM_MODEL_LIGHT=deepseek-flash
```

关于 `base_url` 带不带 `/v1`：如果自检报 404，把地址改成 `https://api.deepseek.com/v1` 再试。两种大多数平台都认，以自检通过为准。

安全：`.env` 只留本机。不要把 key 贴进聊天窗口、工单或提交到 git；泄露了去平台后台 **Revoke** 重新生成。

三、自检：先列模型，再验证（约 1 分钟）

```
python check_llm.py --models      # 第 1 步：列出你账号可用的真实模型名
```

从输出里选一个（带 `←主力` 标记的是当前配置），把名字填回 `.env`。然后：

```
python check_llm.py               # 第 2 步：连通性 + JSON 输出实测
```

三步全绿才算通过：

检查项	不通过时怎么办
配置检查	key 为空 → 会降级 MOCK，不会真调用
连通性	key 错/余额为 0/base_url 不对 → 见脚本给出的提示
JSON 模式	该模型不支持结构化输出 → **换模型**，这步不通全链路必挂

> 为什么非要验 JSON：本系统每个节点（路由、指挥、参谋、仲裁）都要求模型返回结构化 JSON，不是聊天文本。模型不支持 `response_format=json_object`，后面每一环都会解析失败。

⚠ 报「402 Insufficient Balance」怎么办

这是**账户余额为 0**，不是配置错了、也不是模型不行。两条路：

路线 1（推荐，0 成本）：换智谱 GLM —— Flash 系列永久免费

1. 打开 https://bigmodel.cn，手机号注册登录
2. 进入控制台 → **API Keys** → 复制密钥
3. 打开 `config/.env`：把 DeepSeek 那 4 行前面加 `#` 注释掉，把「备选 A：智谱」那 4 行的 `#` 去掉，粘贴新 key
4. 再双击 `1_自检模型.bat`

路线 2：给 DeepSeek 充值（10 元够跑很久；一轮完整验收通常 1 元以内）

> 平台政策会变，各家的赠送额度以官网为准。拿不准就用 `python check_llm.py --models` 看账号到底能用哪些模型。

四、跑验收（约 2 分钟）

```
python run.py --test                              # 跑 6 条验收用例
python run.py "陆军现在多少人，多少装备？"          # 单条提问
python run.py "陆海空联合登陆作战，5天内完成投送，请做联合筹划"
```

看什么：输出的 `[MOCK]` 变成 `[真实模型]`，说明真的在调用了。

用例	期望
T1 陆军人数	答对 **15900 人**，终验 ✅
T2 写周报	拒答
T3 联合登陆	三参谋并行出方案 → 仲裁 → 终验 ✅
T4 海军兵力	答对 **12500 人**，终验 ✅
T5 需求不清	转人工澄清
T6 数字防篡改	拦下 → 回退重跑 → 最终答对

> 注意：T6 的故障注入只在 MOCK 分支生效（`MOCK_FAULT` 环境变量）。接真模型后它会自动跳过，**这是正常的**——数字防篡改的机器校验（HR-07）在真模型下依然全程生效，只是没法再人为注入一个错误数字来演示。

五、语义层质量怎么判（这一步才是重点）

链路跑通 ≠ 方案能用。真模型接入后，请按下面 6 条**逐条看产物**，而不是只看终端输出：

#	判据	怎么看	不达标的表现
1	**数字仍 100% 来自 SQL**	终验 `ok=True`；`plans/*.json` 里每个数字带 `source: sql:q_xxx`	终验报 `FIGURE_MISMATCH`，说明模型自己算了个数字
2	**没有幻觉单位**	方案里的 `unit_id` 必须能在兵力池里查到	终验报 HR-06 违规，出现库里不存在的番号
3	**方案有实质内容**	打开 `plans/陆军.v1.json`，看 `timeline` / `risks`	全是"按计划展开行动"这类空话，等于没规划
4	**三个军种真的不一样**	对比三份 `plans/*.v1.json`	三份像同一个模板套的，说明参谋没进入角色
5	**约束被遵守**	兵力不超上限、不进禁区、不超时限	终验列出具体违规项
6	**稳定性**	**同一条用例跑 3 次**	一次对两次错 = 不可用，需要调 prompt 或换更强模型

产物在哪：

```
plans/陆军.v1.json  海军.v1.json  空军.v1.json   ← 三个参谋各自的方案
plans/final_plan.v1.json                        ← 仲裁后的决心方案
trace/session_*.json                            ← 全流程记录（失败诊断靠它）
```

不达标时的诊断顺序（别一上来就说"模型不行"）：

1. 先看 `trace/` 里 `route` 判对没有 → 判错是**意图层**问题，改 `src/graph/prompts.py`
2. 路由对但方案空 → **参谋简报**不够自包含（忘了给兵力快照），改 `STAFF_PLAN_*` 模板
3. 数字对不上 → HR-07 生效，模型在编数，**加强 prompt 约束**或在 validate 里加更严的校验
4. 以上都对但质量差 → 才是**模型能力**问题，考虑升级到 `deepseek-v4-pro`

六、成本

场景	调用次数	大致花费
单域查询（"陆军多少人"）	2 次（路由轻量 + 参谋主力）	不到 1 分钱
全链路联合筹划	5 次（路由 + 指挥 + 三参谋 + 仲裁）	几分钱
一轮完整验收（6 用例）	约 20 次	**通常 1 元以内**

以官方实时计费为准。**建议先设一个额度上限**（平台后台可设），再跑批量测试，防止异常循环刷爆余额。

七、验证完之后

结论	下一步
6/6 通过且方案质量达标	第一期完成 → 开工**二期：协商子循环**（黑板书落盘 + 收敛判据）
链路通过但方案质量不行	按第五节诊断顺序调 prompt；确认是模型能力问题再升级模型
频繁解析失败/超时	查 `src/llm/client.py` 的重试与超时配置（`LLM_TIMEOUT`），必要时换更稳定的平台

> 一期的核心判据只有两条：**"陆军多少人"答得对** 且 **数字可追溯到 SQL**。这两条过了，一期就算交付。